

一种基于重复数据删除的 Oracle 数据库备份系统

李向前

(四川大学 计算机学院, 四川 成都 610065)

摘要:针对在数据备份服务器中存在大量重复数据的问题,提出了一种基于重复数据删除技术的 oracle 数据库备份系统。系统首先生成临时备份文件,然后把临时文件划分成不重叠的块,通过哈希算法计算每个块的指纹值。在数据灾备中心建立 hash 表记录已存储数据块的指纹值。通过对比指纹值,检测重复数据。为了提高数据安全性,采用了一定的安全机制来防止信息泄露以及数据丢失。实验证明,该系统在实现远程备份的同时,有效地减少了备份的数据。

关键词:数据备份;重复数据删除;Oracle 数据库;安全机制

中图分类号:TP391 **文献标识码:**A **文章编号:**1009-3044(2013)01-0005-03

A Oracle Database Backup System with Data De-duplication

LI Xiang-qian

(Computer Department, Sichuan University, Chengdu 610065, China)

Abstract: To solve the problem of vast amount of duplicate data in the data backup server, a oracle database backup system with data de-duplicate is proposed. The system first generates a temporary backup file, then the temporary file is divided into non-overlapping blocks, fingerprint values calculated for each block through hash algorithm. at the disaster recovery center it sets up the hash table to records the stored fingerprint of the data block. By comparing the fingerprint value to detect duplicate data. In order to improve data security, take some security mechanisms to prevent information leaks and data loss. The experiment shows that the system can reduce backup data effectively in the remote backup.

Key words: data backup; data de-duplication; Oracle database; security measures

Oracle 数据库是美国甲骨文公司推出的一款市场占有率很高的关系数据库管理系统。随着信息技术的快速发展,数据对企业越来越重要,数据丢失以后对企业来讲,其损失是无法估量的,甚至是毁灭性的^[1]。但由于备份数据的爆炸式增长,对数据备份服务器的存储空间需求越来越大,在大量的备份数据中有很大一部分是重复或者相似的数据。为了节省备份服务器的存储空间,节约备份数据传输成本,重复数据删除技术被运用到 Oracle 数据库备份系统中^[2]。

目前,重复数据删除技术主要包括相似数据检测和编码技术,相同数据检测技术。本系统主要运用的是相同数据检测技术。相同数据检测根据检测粒度的不同分为相同文件和相同数据块。完全文件检测对文件内部的重复数据无能为力。相同数据块主要是通过固定分块,可变分块,滑动分块等技术检测重复数据。本系统首先将需要备份的数据放到备份代理处,然后使用滑动块检测技术对备份代理处的文件进行处理,处理掉重复的数据。再把处理后的数据通过 Internet 网传输到远程的备份服务器,存储在备份服务器的磁盘上,在备份服务器上建立分块指纹值的 hash 表并添加分块的指纹值^[3]。

1 Oracle 数据库备份系统架构

Oracle 数据库备份系统的结构如图 1 所示,备份代理通过因特网与远程的备份服务器相连。备份代理首先把数据库中的数据导出生成临时文件,然后按照一定的算法将需要备份的临时文件划分为数据块并计算其指纹值。备份服务器包括管理服务器和存储服务器。管理服务器负责数据库的备份与恢复,存储服务器保存来自备份代理的文件,数据块的指纹值索引表。

2 系统设计与实现

2.1 Oracle 数据导出

在 Oracle 数据库中利用 Export 可以将数据从数据库中提取出来,Oracle 支持三种数据导出模式:表方式(table),用户方式(user),完全方式(full)。在备份代理中用 Export 导出 Oracle 数据库中的数据,生成二进制临时文件^[4]。

2.2 文件分块

收稿日期:2012-11-20

作者简介:李向前(1985-),男,硕士研究生,主要研究方向为网络安全技术及应用。

指纹值比较,判断传过来的数据块是否已经存在于备份中心中。如果不是重复的数据块,就将数据块和数据块的指纹值写入备份服务器的存储服务器中。随着备份服务器中数据块的增多,索引表也越来越大,搜索索引表中的指纹值会变得很低效,为了解决这个问题,对索引表引入二级索引缓存^[3],内存中存放第一级缓存,里面的指纹值是最近发送过来的数据块的指纹值。磁盘中存放第二级缓存,内存中换出的指纹值放在第二级缓存中。

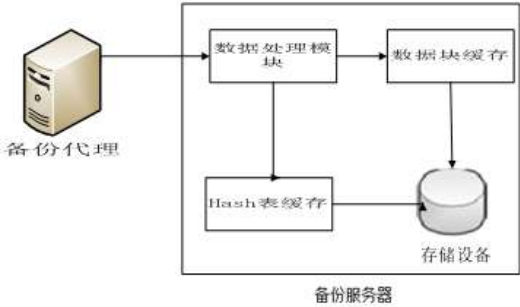


图3 存储数据和 Hash 表示意图

在备份服务器上,当要删除一个文件时,组成该文件的所有数据块都会被删除。上文中提到不同文件可能会共享一些数据块,当删除一个文件中的数据块后,会造成其他文件所共享的数据块丢失。解决这个问题的一般有两种方法:第一是适当引入一定量的冗余数据保证备份数据的安全性^[9],第二是在每个数据块中格外添加一个描述符 Reference count,它记录数据块被共享的次数,每次删除数据块时都检查 Reference count 是否大于一,如果大于一,说明有其他文件在使用数据块,不能删除,否则可以删除数据块。这样便保证了备份文件的安全性。

2.4 Oracle 数据库恢复

当生产服务器上面的 Oracle 数据库遭到破坏或者数据丢失时,用户需要恢复数据库,恢复数据库的一般步骤如下:(1)在远程备份服务器中的第一级缓存索引列表中查找需要恢复文件的数据块指纹值。(2)如果在第一级缓存中没有找到指纹值,继续在第二级缓存索引中查找指纹值(3)按照指纹值依次从备份中心的数据服务器中读出数据块。(4)重复(1)到(3),直到备份代理收到完整的恢复文件。由于备份时数据块是按照顺序存放的,恢复时每读一个数据块都会将其周围块读入缓存中。加快了恢复速度。

3 实验

实验环境为:备份代理和备份服务器的硬件配置是一样的:CPU 是 Intel(R) Core(TM)2 Duo CPU E7500 @2.93GHz 2.94GHz,内存为 2G,硬盘大小为 320G。备份代理的操作系统是 Windows 2003 server,备份服务器安装的操作系统是 CentOS。备份代理和备份服务器通过百兆交换机相连。

本实验的方法是:首先把 Oracle 数据库中的内容备份,然后将备份的内容经过重复数据删除处理后存储到备份服务器上。需要备份的原始数据大小为 935M,1804M,2903M。本次实验采用两种方法进行数据备份,将备份数据压缩后存储数据和需要对备份的数据进行重复数据删除处理后存储数据。

由图 4 可以看出,第一种方法,采用普通压缩技术压缩备份文件,经过压缩备份数据以后,备份数据比原始数据要少,减少了数据存储空间。第二种方法采用重复数据删除技术处理备份数据,图 4 显示,当备份数据为 935M 时,通过重复数据删除技术处理的备份数据要略大于通过压缩方法处理的数据,这是因为刚开始备份重复数据很少,再加上重复数据删除技术需要存储数据块的索引表,需要额外的存储空间。在处理 1804M 备份数据时,重复删除技术占用的空间比压缩技术占用的空间小,2903M 备份数据时,差距加大。




图4 实验数据对比

图 4 还表明,随着 Oracle 数据库备份的次数增加,备份代理和备份服务器中的重复数据会越来越多,重复数据删除技术相对于压缩技术的优势也越来越大。在 Oracle 数据库备份中应用重复数据删除技术能够更好的节约存储空间,节省网络带宽。

4 结束语

本文设计并实现了一种基于重复数据删除的 Oracle 数据库备份系统,该系统可以进行远程备份与恢复,本系统采用重复数据删 (下转第 14 页)

2)将分析处理的结果送到XML的解析器(DOM、JDOM或者SAX)中进行解析,将其中的内容转换到JAVA对象中。

3)连接目标数据库,把JAVA对象中的数据插入到目标数据库中。

基于模型的驱动映射结构简单,使用易用,但是和基于模板的驱动相比,它不够灵活,因为它映射的是具体的数据模型,不过可以通过XSL实现其灵活性。

3 结束语

本文介绍了采用JAVA技术和XML技术实现临盘采油厂的数据转换接口的实现方法。此方法可以很好的实现数据的迁移,采用XML作为中间数据存储结构很好的屏蔽了数据库系统之间的差异性,如数据结构、数据类型等,而且XML和JAVA都具有很好的跨平台性,可以实现了系统的跨平台性。

参考文献:

- [1] 尹建璋.基于XML的应用层数据交换技术的研究[J].计算机与现代化,2009(11).
- [2] 张欣欣.综合录井仪数据迁移及转换接口技术研究[D].中国石油大学,2008.
- [3] 孔翔鹰,李治柱.XML与数据库双向接口的研究和实现[J].微型电脑应用,2006,9(22):48-52.
- [4] 周竞涛.基于XML的异构数据库集成中间件技术研究[D].西安:西北工业大学,2002.
- [5] Giuseppe Psaila.ERX:An ExPerience inIntegrating ER Models RDB and XML Teclinologies .EDBT 2002 Workshops .LNCS,2490.2002: 242-265.
- [6] 戴永寿,张淑英.基于JAVA和XML的综合录井仪数据转换接口技术进展[J].录井工程, 2008,19(2).
- [7] 郑仕勇,李碧青.基于XML和中间件的数据迁移模型研究与设计[J].软件导刊, 2012,11(4).
- [8] 王云晓,张学诚,屈彪.基于XML的构件库管理系统实现研究[J].计算机应用与软件,2009(26).
- [9] 欧阳峥峥,李禹生.基于XML的异构数据库数据交换中间件的研究[J].计算机与现代化,2008(12).
- [10] 李钟隽.基于XML数据迁移中间件的研究[D].哈尔滨:哈尔滨工程大学,2007.

(上接第7页)

除技术删除 Oracle 数据库系统中的重复数据,实验表明,重复删除技术删除了备份服务器中的重复数据块,备份次数越多,效果越好。提高了备份服务器中存储空间利用率,也降低了备份系统对网络带宽的要求。通过给数据块增加 Reference count 有效的保护了备份数据安全。本系统在保证备份数据安全的同时,减少了存储空间。

参考文献:

- [1] 李涛.信息系统容灾抗毁原理与应用[M].北京:人民邮电出版社,2007.
- [2] Muthitacharoen A, Chen B, Mazieres D. A low-bandwidth network file system. In: Proc. of the 18th ACM Symp. on Operating System Principles (SOSP 2001). New York: ACM Press, 2001, 174-187.
- [3] Tianming Yang, Dan Feng, Jingning Liu, Yaping Wan, Zhongying Niu, Yuchang Ke. "3DNBS: A Data De-duplication Disk-Based Network Backup System". NAS 2009: 287-294.
- [4] 李锁雷. Oracle 数据块备份与恢复研究[J]. 信息安全与技术, 2011(9): 99-100.
- [5] Bobbarjung DR, Jagannathan S, Dubnicki C. Improving duplicate elimination in storage systems. ACM Trans. on Storage, 2006, 2(4): 424-448.
- [6] 敖莉, 舒继武, 李明强. 重复数据删除技术[J]. 软件学报, 2010(05): 918-920.
- [7] Langford J. Multiround rsync. [2012-01-01]. <http://www.cs.cmu.edu/~jcl/research/mrsync/mrsync.ps>
- [8] BRODER A Z. Identifying and Filtering Near-duplicate Documents [C]// Proceedings of the 11th Annual Symposium on Combinatorial Pattern Matching (CPM'00), Jun 21-23, 2000, Montreal, Canada. Berlin, Germany: Springer-Verlag, 2000: 1-10.
- [9] Han B, Keleher P. Implementation and performance evaluation of fuzzy file block matching. In: Proc. of the 2007 USENIX Annual Technical Conf. (USENIX 2007). Berkeley. USENIX Association, 2007: 199-204.